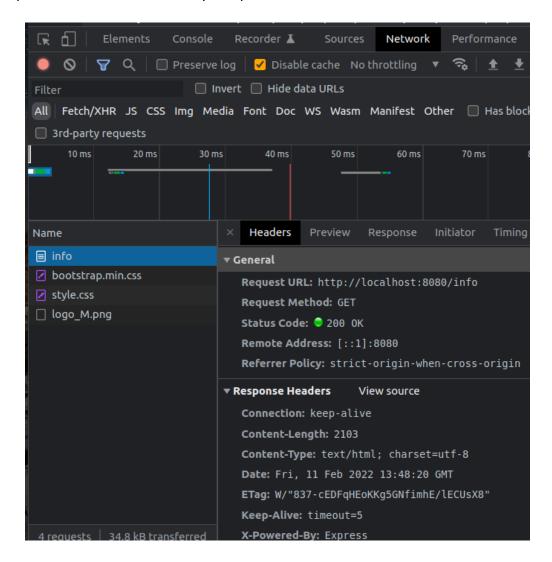
Análisis de performance del servidor

Compresión GZIP

Analizaremos sobre la ruta **/info** con y sin compresión, la diferencia de cantidad de bytes devueltos en un caso y otro.

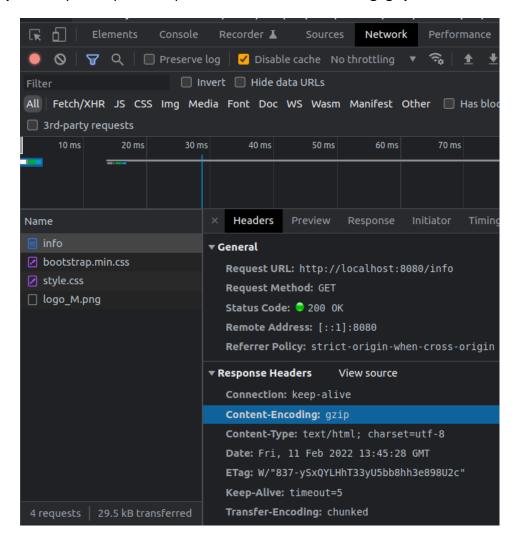
A continuación, se muestran los headers de la respuesta del servidor y el tamaño del paquete enviado cuando NO hay compresión.



El tamaño transferido del documento "info" es de 2.3KB y el de "styles.css" de 6.5KB.

Name	Status	Туре	Initiator	Size	Time
■ info	200	document	Other	2.3 kB	2 ms
bootstrap.min.css	200	stylesheet	<u>info</u>	24.8 kB	66 ms
✓ style.css	200	stylesheet	<u>info</u>	6.5 kB	2 ms
☐ logo_M.png	200	png	Other	1.2 kB	2 ms

Ahora vemos los headers para el caso con compresión, activando el middleware compression para Express. Se puede ver el Content-Encoding: gzip.



En este caso, el tamaño transferido del documento "info" es de **1.3KB** y el de "styles.css" de **2.1KB** .

Name	Status	Туре	Initiator	Size	Time
■ info	200	document	Other	1.3 kB	3 ms
✓ bootstrap.min.css	200	stylesheet	<u>info</u>	24.8 kB	66 ms
✓ style.css	200	stylesheet	<u>info</u>	2.1 kB	2 ms
☐ logo_M.png	200	png	Other	1.2 kB	1 ms

El **porcentaje de compresión** en este caso es de un **43**% y un **68**% respectivamente, lo cual es mucho.

Hay que analizar cada caso que se nos platee, para ver si es más performante usar o no la compresión, porque si bien se logra disminuir el tamaño de la información transferida, esto es a costa de un mayor trabajo por parte del servidor (que debe realizar esta tarea). En casos de alto tráfico, no suele ser una buena opción.

Profiling

Vamos a trabajar sobre la ruta /info, en modo fork, agregando o extrayendo un console.log de la información colectada antes de devolverla al cliente.

Para ambas condiciones (con o sin console.log) en la ruta '/info', obtenemos:

- 1) El perfilamiento del servidor, realizando el test con --prof de node.js. Analizamos los resultados obtenidos luego de procesarlos con --prof-process.
- a) Utilizamos como test de carga Artillery en línea de comandos, emulando 50 conexiones concurrentes con 20 request por cada una.

Reporte de Artillery CON console.log:

```
      Summary report @ 18:06:22(-0300)

      http.codes.200:
      1000

      http.request_rate:
      978/sec

      http.requests:
      1000

      http.response_time:
      0

      min:
      0

      max:
      23

      median:
      5

      p95:
      8.9

      p99:
      13.1

      http.responses:
      1000

      vusers.completed:
      50

      vusers.created:
      50

      vusers.created_by_name.0:
      50

      vusers.session_length:
      52

      max:
      183.1

      median:
      52

      max:
      183.1

      median:
      108.9

      p95:
      149.9

      p99:
      162.4
```

Reporte de Artillery SIN console.log:

```
      Summary report @ 17:49:03(-0300)

      http.codes.200:
      1000

      http.request_rate:
      998/sec

      http.response_time:
      0

      max:
      25

      median:
      3

      p95:
      6

      p99:
      8.9

      http.responses:
      1000

      vusers.completed:
      50

      vusers.created_by_name.0:
      50

      vusers.created_by_name.0:
      50

      vusers.session_length:

      min:
      23.6

      max:
      123.2

      median:
      61

      p95:
      117.9

      p99:
      117.9

      p99:
      120.3
```

Se ve como la prueba SIN el console.log aumenta la performance, obteniéndose mejores tasas de respuestas/seg, tiempo medio de respuesta y duración de sesiones por usuario virtual.

El mismo comportamiento se ve también al analizar el resultado del profiling y teniendo en cuenta la cantidad de ticks que requirió una y otra prueba:

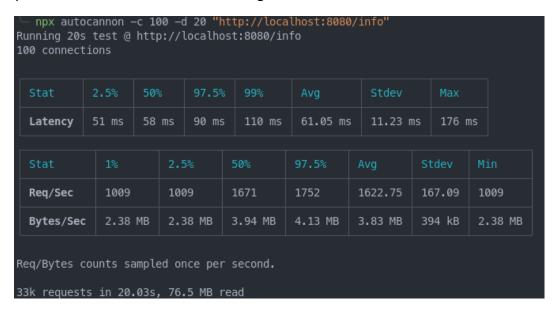
CON console.log

SIN console.log

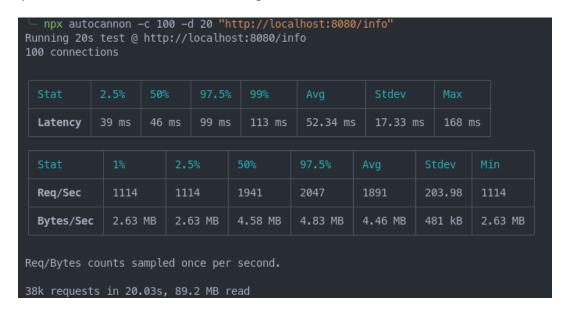
```
[Summary]:
 ticks total nonlib
                        name
   90
         4.0%
                21.3%
                       JavaScript
  333
        15.0%
                78.7% C++
                45.2% GC
  191
         8.6%
                       Shared libraries
        81.0%
 1803
```

b) Ahora utilizaremos Autocannon en línea de comandos, emulando 100 conexiones concurrentes realizadas en un tiempo de 20 segundos.

Reporte de Autocannon CON console.log:



Reporte de Autocannon SIN console.log:



Nuevamente el mismo comportamiento mostrando mejor performance SIN el console.log. Se nota tanto en las peticiones totales dentro de los 20 segundos de test, en la latencia y en la tasa de respuestas por segundo.

El análisis del resultado del profiling también es concordante.

CON console.log

```
[Summary]:
ticks total nonlib name
2243 11.0% 50.1% JavaScript
2198 10.8% 49.1% C++
1142 5.6% 25.5% GC
15885 78.0% Shared libraries
```

SIN console.log

```
[Summary]:
 ticks total nonlib
                      name
 2350
        11.6%
               51.6%
                     JavaScript
 2182
        10.8%
               47.9% C++
 1070
        5.3%
               23.5% GC
        77.5%
 15681
                     Shared libraries
```

- 2) El perfilamiento del servidor con el modo inspector de node.js --inspect.
- a) Utilizamos como test de carga Artillery en línea de comandos, emulando 50 conexiones concurrentes con 20 request por cada una.

Reporte de Artillery CON console.log:

```
      Summary report @ 22:01:08(-0300)

      http.codes.200:
      1000

      http.request_rate:
      646/sec

      http.response_time:
      1

      min:
      1

      max:
      103

      median:
      29.1

      p95:
      51.9

      p99:
      66

      http.responses:
      1000

      vusers.completed:
      50

      vusers.created_by_name.0:
      50

      vusers.session_length:
      50

      min:
      154.3

      max:
      806.9

      median:
      671.9

      p95:
      772.9

      p99:
      788.5
```

Reporte de Artillery SIN console.log:

```
      Summary report @ 22:04:40(-0300)

      http.codes.200:
      1000

      http.request_rate:
      970/sec

      http.requests:
      1000

      http.response_time:
      15

      min:
      0

      max:
      15

      median:
      5

      p95:
      10.1

      p99:
      13.1

      http.responses:
      1000

      vusers.completed:
      50

      vusers.created by_name.0:
      50

      vusers.session_length:
      50

      min:
      60

      max:
      169.3

      median:
      117.9

      p95:
      156

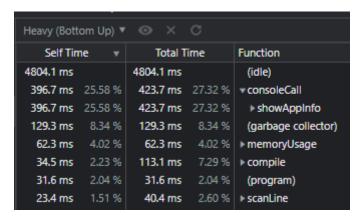
      p99:
      162.4
```

Al igual que en el punto 1), se observa exactamente el mismo comportamiento de mayor performance en la variante SIN console.log en los mismos parámetros que citamos anteriormente.

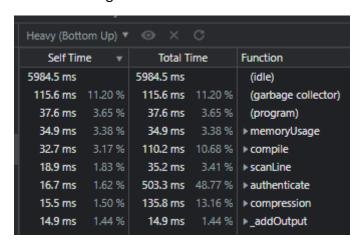
El perfilamiento por --inspect es algo distinto al de --perf y 0x (también usa --perf por dentro) y permite capturar mejor los stacks de las funciones. Pero también reduce la performance de la prueba en general. Se nota mucho más en el caso del console.log y también puede verificarse que se imprimen completamente todos los registros por consola en el navegador y de manera sincrónica.

Analicemos los datos del stack que nos arroja inspect:

CON console.log:



SIN console.log

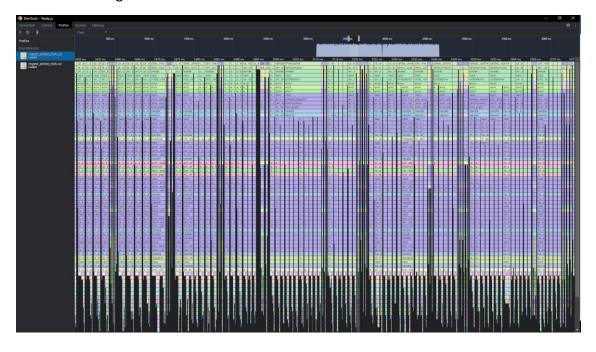


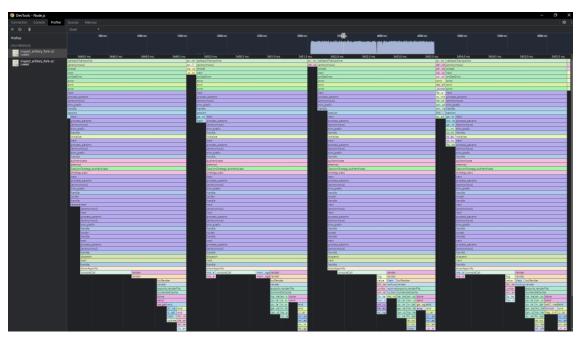
Se observa claramente como en el caso CON console.log, esta función es la de mayor tiempo propio y que permanece en la parte superior del stack, ya que se trata de una función síncrona bloqueante. Es llamada por el controlador **showAppInfo**.

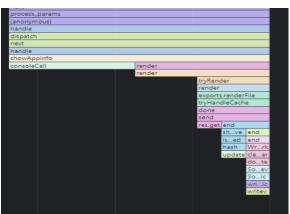
Para el caso de SIN console.log, no se registran funciones de gran tiempo propio. Corresponde a un comportamiento asíncrono (no bloqueante).

Veamos las gráficas donde se pone en evidencia más claramente lo anterior.

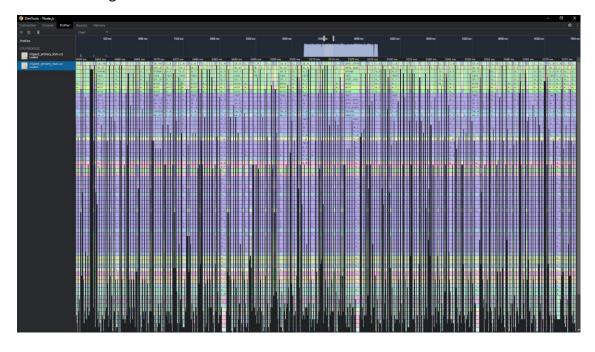
CON console.log

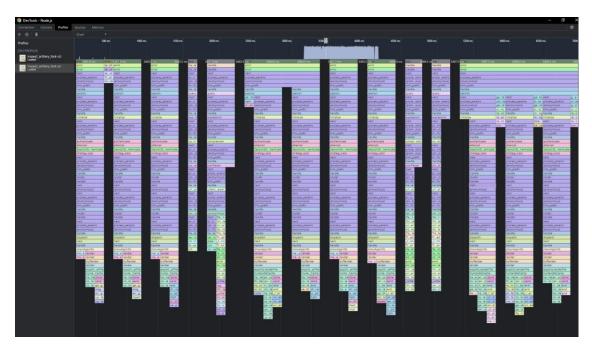


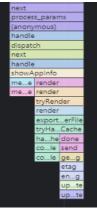




SIN console.log





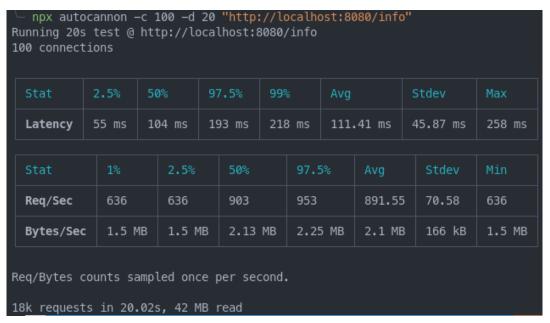


Ambos gráficos presentan la misma escala. Puede verse como el segundo (SIN console.log) es más "puntiagudo" indicando una naturaleza asíncrona. Mientras que el primero, posee picos más anchos resultando menos agudo. Debido a la naturaleza síncrona de la función console.log que durante su ejecución bloquea el stack de funciones.

Obviamente este bloqueo por los ms que dura la ejecución de la función, es lo que provoca que se ensanchen esos picos y cada petición demande más tiempo en ser completada. Disminuyendo la performance del servidor.

b) Ahora utilizaremos Autocannon en línea de comandos, emulando 100 conexiones concurrentes realizadas en un tiempo de 20 segundos.

Reporte de Autocannon CON console.log:



Reporte de Autocannon SIN console.log:

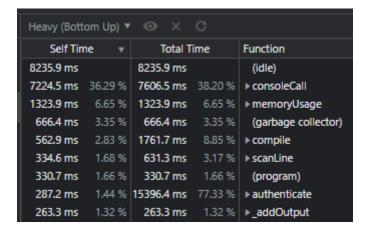


Otra vez evidencia el mismo comportamiento mostrando mejor performance SIN el console.log. Como antes, se nota tanto en las peticiones totales dentro de los 20 segundos de test, en la latencia y en la tasa de respuestas por segundo.

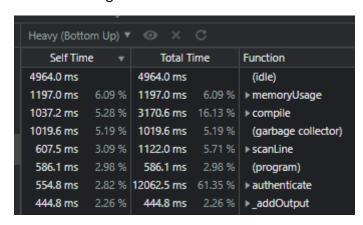
Si analizamos el resultado del inspect, tanto la tabla de las funciones como la gráfica muestran el mismo comportamiento.

Solo se presenta el resultado de las tablas, para no redundar en la misma información.

CON console.log:



SIN console.log

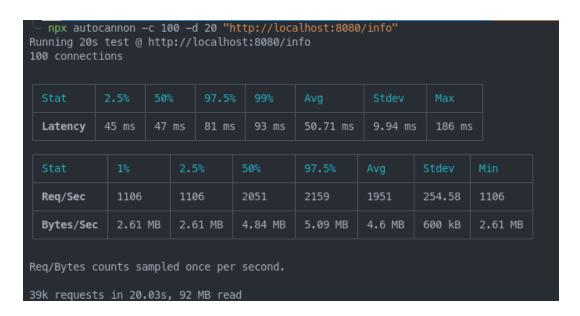


3) El diagrama de flama con 0x, emulando la carga con Autocannon con los mismos parámetros anteriores.

Reporte de Autocannon CON console.log:

Stat	2	.5%	50%		97.5%	99%	Avg	Stdev	Max	
Latency	5	1 ms	55	ms	95 ms	100 ms	59.5 ms	11.57 ms	175 ms	
Stat		1%		2.5	j%	50%	97.5%	Avg	Stdev	Min
Req/Sec		947		947		1722	1893	1664.85	225.19	947
Bytes/Sec	:	2.23	МВ	2.2	23 MB	4.06 MB	4.46 MB	3.93 MB	531 kB	2.23 MB

Reporte de Autocannon SIN console.log:



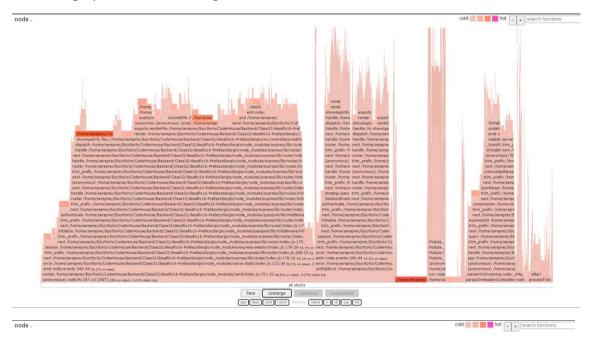
El mismo comportamiento de siempre, mostrando mejor performance SIN el console.log. Se nota tanto en las peticiones totales dentro de los 20 segundos de test, en la latencia y en la tasa de respuestas por segundo.

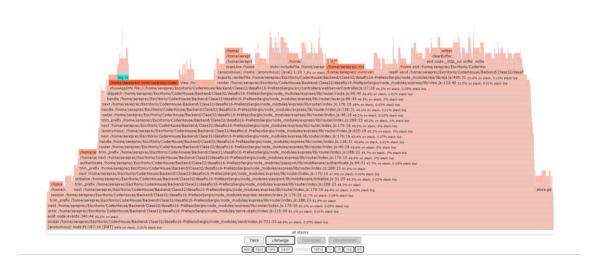
Nótese que los resultados son casi idénticos a cuando se utilizó **node --perf**. Y esto tiene que ver con que **0x** utiliza internamente este profiler como mencioné anteriormente cuando marcaba la diferencia con **node --inspect**.

Ox y node –perf, presentan el "inconveniente" de que en ciertas situaciones se pierde información del stack de funciones. Y las mismas aparecen bajo otro rótulo.

Por último, analicemos los gráficos de flama para cada escenario y veamos si aparece representada la situación que hemos venido observando.

Ox flame graph CON console.log







Ox flame graph SIN console.log



Este gráfico es distinto al del inspect, ya que en este caso, el eje horizontal no es la escala del tiempo.

En el caso del **inspect** se muestran cómo van sucediendo todos los procesos del programa y las pilas de stack a lo largo del tiempo (eje x). Se puede registrar como se desarrolla cada petición a lo largo de la duración del test.

En el **gráfico de flama de 0x**, se representa una gráfica global de las funciones en el stack en base a los muestreos que se toman a lo largo de todo el test. No se grafican las instantáneas del stack a lo largo del tiempo, sino que se procesa esa información en conjunto y se trabaja en términos porcentuales. El ancho de los bloques corresponde al porcentaje de tiempo que dicha función aparece en esa posición del stack.

Los colores representan cuan "caliente" es una función en relación a su mayor permanencia en la parte superior del stack de funciones. Cuanto mayor sea el porcentaje de tiempo en esta parte, más caliente es.

Este comportamiento se asocia a las funciones síncronas bloqueantes, que permanecen mucho tiempo en la cima del stack bloqueando el proceso.

Puede verse como en el primer caso (CON console.log), se registra un color más "caliente" y se corresponde a la ejecución del console.log, cosa que no ocurre con el segundo de los casos donde las coloraciones, y por ende, la permanencia de las funciones en la cima del stack es más pareja (asincronismo).

En resumen, todos los test concuerdan en que la incorporación del console.log trae como resultado una baja apreciable de la performance del servidor.

Al analizar los números del profiling junto a los gráficos de flama de 0x y las gráficas del inspect, se llega a la conclusión de que lo anterior es producto que la función console.log es síncrona, bloqueando el proceso durante su ejecución y aumentando los tiempos de procesamiento de las solicitudes.